NewsRetrieval: informe de benchmark

BORRADOR PROVISIONAL - los juicios de relevancia aun no han sido aprobados.

Integrantes del equipo: pendientes de completar por el equipo.

1. Objetivo

Construir y evaluar un sistema escolar de recuperacion lexica Top-10 sobre 2,000 noticias, manteniendo una comparacion reproducible entre 12 representaciones VSM.

2. Fuentes y corpus

El corpus fijo contiene 2,000 noticias en ingles de Wikinews, Global Voices y EFF. Se conservan titulo, cuerpo, identificador, fecha, autoria, licencia y enlace original.

3. Normalizacion

Se usa spaCy para tokenizacion, POS y lematizacion. Se eliminan de forma selectiva determinantes, preposiciones, conjunciones y pronombres, manteniendo otros terminos informativos.

4. Representaciones VSM

Se comparan campo titulo o cuerpo, unigramas o bigramas y frecuencia, binaria o TF-IDF. La configuracion principal es cuerpo, unigramas y TF-IDF.

5. Benchmark

Hay 15 consultas: cinco faciles, cinco intermedias y cinco dificiles, agrupadas en cinco necesidades. Cada consulta tiene entre 10 y 15 juicios propuestos con niveles 1 y 2.

6. Matriz de propuestas

data/relevance_review.tsv contiene los 10,000 pares necesidad-documento y propuestas 0, 1 o 2 elaboradas sin consultar puntuaciones ni posiciones VSM. Los positivos, ambiguos y negativos sospechosos requieren aprobacion humana; la matriz no equivale a juicios humanos cerrados. Los candidatos se documentan en data/candidates_review.tsv y el estado provisional de qrels.tsv se conserva por separado en data/benchmark_status.tsv.

7. Resultados provisionales

Consulta	P@10	R@10	F1@10	MRR	nDCG@10
Q01	0.500	0.333	0.400	1.000	0.452
Q02	0.100	0.067	0.080	0.125	0.073
Q03	0.000	0.000	0.000	0.000	0.000
Q04	0.500	0.417	0.455	1.000	0.601
Q05	0.500	0.417	0.455	1.000	0.520
Q06	0.000	0.000	0.000	0.000	0.000
Q07	0.000	0.000	0.000	0.000	0.000
Q08	0.100	0.100	0.100	0.500	0.060
Q09	0.000	0.000	0.000	0.000	0.000
Q10	0.400	0.364	0.381	0.250	0.305
Q11	0.500	0.455	0.476	0.500	0.441
Q12	0.500	0.455	0.476	0.333	0.438
Q13	0.500	0.357	0.417	0.500	0.465
Q14	0.500	0.357	0.417	1.000	0.291
Q15	0.000	0.000	0.000	0.000	0.000
MEDIA	0.273	0.221	0.244	0.414	0.243

Estas cifras son experimentales y no deben presentarse como evaluacion academica definitiva.

8. Comparacion y analisis

La tabla comparison.tsv contiene las 12 configuraciones y sus medias por dificultad. Las conclusiones se mantienen descriptivas: los rankings reales se conservan para observar sinonimos, baja coincidencia lexica, ambiguedad, nombres propios, vocabulario tecnico y efectos de la normalizacion.

Cinco consultas con mejor nDCG provisional: Q04, Q05, Q13, Q01, Q11.

Cinco consultas con menor nDCG provisional: Q03, Q06, Q07, Q09, Q15. Se conservaran como casos de error para una futura comparacion, sin implementar embeddings.

9. Limitaciones y conclusiones

La recuperacion es lexica y depende de la coincidencia entre la consulta normalizada y el texto. Las consultas dificiles pueden producir ceros cuando expresan una intencion sin compartir vocabulario con los documentos. La aprobacion humana puede cambiar qrels y, por tanto, todas las metricas.

10. Estado de entrega

Se generaron 150 rankings provisionales para la configuracion principal y las 12 configuraciones. Para congelar: revisar candidates_review.tsv, corregir qrels.tsv, retirar la marca PROVISIONAL y ejecutar python main.py --benchmark --frozen.